

# Formules de stats descriptives pour les échantillons (notations : $n, \bar{x}, s$ )

Présentation des données	<b>Données isolées (ou énumérées)</b>	<b>Données groupées (valeurs et fréq.)</b> Ex. : {3, 3, 3, 3, 8, 8, 8, 8, 8, 11, 11, 11, 11, 14, 14} ( $k=4$ valeurs distinctes)	<b>Données groupées par classes</b> Ex. : ( $k=6$ classes)																																				
	Ex. : {2, 5, 5, 6, 8, 9, 12, 13, 15, 16, 16, 20, 21, 23, 24, 25}	<table><tr><th><math>v_i</math></th><th>Fréq. <math>f_i</math></th><th>Fréq.cum. <math>F_i</math></th></tr><tr><td><math>v_1=3</math></td><td>4</td><td>4</td></tr><tr><td>8</td><td>6</td><td>10</td></tr><tr><td>11</td><td>4</td><td>14</td></tr><tr><td><math>v_4=14</math></td><td>2</td><td><math>16=n</math></td></tr></table>	$v_i$	Fréq. $f_i$	Fréq.cum. $F_i$	$v_1=3$	4	4	8	6	10	11	4	14	$v_4=14$	2	$16=n$	<table><tr><th>Pt milieu <math>m_i</math></th><th>fréquence <math>f_i</math></th><th>Fréq.cum. <math>F_i</math></th></tr><tr><td>60</td><td>2</td><td>2</td></tr><tr><td>80</td><td>8</td><td>10</td></tr><tr><td>100</td><td>12</td><td>22</td></tr><tr><td>120</td><td>6</td><td>28</td></tr><tr><td>140</td><td>3</td><td>31</td></tr><tr><td>160</td><td>1</td><td>32=<math>n</math></td></tr></table>	Pt milieu $m_i$	fréquence $f_i$	Fréq.cum. $F_i$	60	2	2	80	8	10	100	12	22	120	6	28	140	3	31	160	1	32= $n$
	$v_i$	Fréq. $f_i$	Fréq.cum. $F_i$																																				
	$v_1=3$	4	4																																				
8	6	10																																					
11	4	14																																					
$v_4=14$	2	$16=n$																																					
Pt milieu $m_i$	fréquence $f_i$	Fréq.cum. $F_i$																																					
60	2	2																																					
80	8	10																																					
100	12	22																																					
120	6	28																																					
140	3	31																																					
160	1	32= $n$																																					
$n = 16; x_1 = 2, \dots, x_{16} = 25$	Dans les notes de cours, $v_i$ était noté aussi $x_i$ 😊; $x_1 = 3, \dots, x_{16} = 16$																																						

## Mesures de tendance centrale

Moyenne	$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$	$\bar{x} = \frac{\sum_{i=1}^k f_i v_i}{n}$	$\bar{x} = \frac{\sum_{i=1}^k f_i m_i}{n}$
	$\bar{x} = \frac{2+5+5+\dots+24+25}{16} = \frac{220}{16} = 13,75$	$\bar{x} = \frac{(4)(3) + (6)(8) + (4)(11) + (2)(14)}{16} = \frac{132}{16} = 8,25$	$\bar{x} = \frac{(2)(60) + (8)(80) + (12)(100) + (6)(120) + (3)(140) + (1)(160)}{32} = \frac{3\,260}{32} = 101,875$
Médiane	$Me = x_{\left[\frac{n+1}{2}\right]}$ où la notation $[ ]$ en indice permet d'aller chercher dans les données énumérées et triées celle (ou une moyenne de celles) au centre. Par exemple, $x_{\left[\frac{3+1}{2}\right]} = x_2$ tandis que $x_{\left[\frac{4+1}{2}\right]} = x_{[2.5]} = x_2 + 0.5(x_3 - x_2) = \frac{x_2 + x_3}{2}$		Cas particulier de $C_{50}$ , car $Me=Q_2=C_{50}$ . [Voir les centiles plus bas pour description des paramètres.] $Me = L + \left(\frac{\frac{n}{2}-F}{f}\right) \cdot a$ $= 90 + \left(\frac{\frac{32}{2}-10}{12}\right) \cdot 20 = 100$
	Ex. : $Me = x_{\left[\frac{16+1}{2}\right]} = x_{[8.5]} = \frac{x_8 + x_9}{2} = \frac{13 + 15}{2} = 14$	Ex. : $Me = x_{\left[\frac{16+1}{2}\right]} = x_{[8.5]} = \frac{x_8 + x_9}{2} = \frac{8 + 8}{2} = 8$	
Mode	Valeur(s) la plus fréquente		Classe modale : classe avec la plus grande fréquence
	Ex. : Mode = 5 ou 16 (bimodal)	Ex. : Mode = 8	Ex. : Classe [90, 110[

## Mesures de dispersion

Variance (pour échantillon)	$s^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}}{n-1}$	$s^2 = \frac{\sum_{i=1}^k f_i v_i^2 - \frac{(\sum_{i=1}^k f_i v_i)^2}{n}}{n-1}$	$s^2 = \frac{\sum_{i=1}^k f_i m_i^2 - \frac{(\sum_{i=1}^k f_i m_i)^2}{n}}{n-1}$
	Ex. : $\sum_{i=1}^n x_i^2 = (2)^2 + (5)^2 + \dots + (25)^2 = 3\,856$ $(\sum_{i=1}^n x_i)^2 = (2+5+\dots+25)^2 = (220)^2 = 48\,400$ d'où $s^2 = \frac{3\,856 - \frac{48\,400}{16}}{15} = 55,4$	Ex. : $\sum_{i=1}^k f_i v_i^2 = (4)(3)^2 + (6)(8)^2 + (4)(11)^2 + (2)(14)^2 = 1\,296$ $(\sum_{i=1}^k f_i v_i)^2 = ((4)(3) + (6)(8) + (4)(11) + (2)(14))^2 = 132^2 = 17\,424$ d'où $s^2 = \frac{1\,296 - \frac{17\,424}{16}}{15} = 13,8$	$\sum_{i=1}^k f_i m_i^2 = (2)(60)^2 + (8)(80)^2 + \dots + (1)(160)^2 = 349\,200$ $(\sum_{i=1}^k f_i m_i)^2 = ((2)(60) + (8)(80) + \dots + (1)(160))^2 = 3\,260^2 = 10\,623\,600$ d'où $s^2 = \frac{349\,200 - \frac{10\,623\,600}{32}}{31} = 551,2097$
Écart-type échantillon	$s = \sqrt{s^2}$	$s = \sqrt{s^2}$	$s = \sqrt{s^2}$
	Ex. : $s = \sqrt{55,4} \approx 7,443$	Ex. : $s = \sqrt{13,8} \approx 3,715$	Ex. : $s = \sqrt{551,2097} \approx 23,48$

Mesures de position (une donnée $x_0$ vs groupe ou des balises globales sur le groupe)			
Quartiles	On ramène le quartile au centile correspondant : $Q_1=C_{25}$ , $Q_2=C_{50}$ et $Q_3=C_{75}$		
Centiles	$C_i = x_{\left[\frac{n \cdot i}{100} + \frac{1}{2}\right]}$	$C_i = x_{\left[\frac{n \cdot i}{100} + \frac{1}{2}\right]}$ mais il faut utiliser les fréquences cumulées pour connaître la valeur des $x_{[\ ]}$ (savoir à l'intérieur de quelles valeurs répétées).	$C_i = L + \left( \frac{\frac{n \cdot i}{100} - F}{f} \right) \cdot a$ <p> <math>L</math> = limite inférieure de la classe contenant le quantile.  <math>n</math> = taille de l'échantillon.  <math>f</math> = fréquence absolue de la classe contenant le quantile.  <math>F</math> = fréquence cumulée de la classe qui précède la classe contenant le quantile.  <math>a</math> = amplitude de la classe contenant le quantile. </p>
	Ex. : $Q_3 = C_{75} = x_{\left[\frac{16 \cdot 75}{100} + \frac{1}{2}\right]} = x_{[12.5]}$ $= x_{12} + (0.5)(x_{13} - x_{12})$ $= 20 + (0.5)(21 - 20) = 21,5$	Ex. : $C_{20} = x_{\left[\frac{16 \cdot 30}{100} + \frac{1}{2}\right]} = x_{[4.1]}$ $= x_4 + (0.1)(x_5 - x_4)$ $= 3 + (0.1)(8 - 3) = 3,5$	$Q_1 = C_{25} = L + \left( \frac{\frac{n \cdot 25}{100} - F}{f} \right) \cdot a = 70 + \left( \frac{\frac{32 \cdot 25}{100} - 2}{8} \right) \cdot 20 = 85$ car d'après les fréq. cum., $\frac{32 \cdot 25}{100} = 8^{\text{ième}}$ donnée; dans la classe [70,90[
Cote Z	Pour obtenir la cote Z d'une valeur d'une donnée particulière $x_0$ on soustrait la moyenne et divise par l'écart-type : $Z = \frac{x_0 - \bar{x}}{s}$		
	Ex. : la cote Z de la donnée 9 : $Z = \frac{x_0 - \bar{x}}{s} = \frac{(9 - 13,75)}{7,443} = -0,64$	Ex. : la cote Z de la donnée 11 : $Z = \frac{x_0 - \bar{x}}{s} = \frac{(11 - 8,25)}{3,715} = 0,61$	Ex. : la cote Z d'une donnée valant 142 : $Z = \frac{x_0 - \bar{x}}{s} = \frac{(142 - 101,875)}{23,48} = 1,71$
Formules de stats descriptives pour les <b>populations</b> (notations : $N$ , $\mu$ , $\sigma$ ) [juste ce qui diffère des formules pour les échantillons plus haut]			
Moyenne	$\mu = \frac{\sum_{i=1}^n x_i}{N}$	$\mu = \frac{\sum_{i=1}^k f_i v_i}{N}$	$\mu = \frac{\sum_{i=1}^k f_i m_i}{N}$
	Juste le symbole change ( $\mu$ , lire «mu», au lieu de $\bar{x}$ ) pas les formules car $N=n$ numériquement. Revoir les ex. ci-haut pour les échantillons.		
Variance (pour une population)	$\sigma^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{N}}{N}$	$\sigma^2 = \frac{\sum_{i=1}^k f_i v_i^2 - \frac{(\sum_{i=1}^k f_i v_i)^2}{N}}{N}$	$\sigma^2 = \frac{\sum_{i=1}^k f_i m_i^2 - \frac{(\sum_{i=1}^k f_i m_i)^2}{N}}{N}$
	Ex. : $\sum_{i=1}^n x_i^2 = idem = 3\,856$ $(\sum_{i=1}^n x_i)^2 = idem = (220)^2$ d'où $\sigma^2 = \frac{3\,856 - \frac{220^2}{16}}{16} = 51,9375$	Ex. : $\sum_{i=1}^k f_i v_i^2 = idem = 1\,296$ $(\sum_{i=1}^k f_i v_i)^2 = idem = 132^2$ d'où $\sigma^2 = \frac{1\,296 - \frac{132^2}{16}}{16} = 12,9375$	$\sum_{i=1}^k f_i m_i^2 = idem = 349\,200$ $(\sum_{i=1}^k f_i m_i)^2 = idem = 3\,260^2$ d'où $\sigma^2 = \frac{349\,200 - \frac{3\,260^2}{32}}{32} = 553,984375$ Idem : Mêmes sommes qu'avec les échantillons... ...seule la 2 <sup>e</sup> division par $N$ au lieu de $n-1$ change.
Écart-type population	$\sigma = \sqrt{\sigma^2}$	$\sigma = \sqrt{\sigma^2}$	$\sigma = \sqrt{\sigma^2}$
	Ex. : $\sigma = \sqrt{51,9375} \approx 7,207$	Ex. : $\sigma = \sqrt{12,9375} \approx 3,597$	Ex. : $\sigma = \sqrt{553,984375} \approx 23,11$
$Z = \frac{x_0 - \bar{\mu}}{\sigma}$	Ex. : la cote Z de la donnée 9 : $Z = \frac{x_0 - \bar{\mu}}{\sigma} = \frac{(9 - 13,75)}{7,207} = -0,66$	Ex. : la cote Z de la donnée 11 : $Z = \frac{x_0 - \bar{\mu}}{\sigma} = \frac{(11 - 8,25)}{3,597} = 0,76$	Ex. : la cote Z d'une donnée valant 142 : $Z = \frac{x_0 - \bar{\mu}}{\sigma} = \frac{(142 - 101,875)}{23,11} = 1,74$